

Analiza Danych Formuły 1: Jak technika zmieniała wyścigi przez ponad 70 lat

Przedmiot: Analiza danych w języku Python (biblioteka pandas) **Skład sekcji (zespołu):** Igor Barcik, Łukasz Domagała **Kierunek:** Informatyka **Rok:** 2026

Spis treści

Analiza Danych Formuły 1: Jak technika zmieniała wyścigi przez ponad 70 lat	1
1. Co badamy i dlaczego	1
2. Skąd dane i co zawierają	2
2.1. Skąd wzięliśmy dane	2
2.2. Jak duże są dane	2
2.3. Najważniejsze tabele	2
2.4. Czyszczenie danych przed analizą	3
3. Analiza danych	3
3.1. Jak ciężar paliwa wpływa na czas okrążenia	3
3.2. Czy 3 najlepsze zespoły zgarniają wszystko	6
3.3. Który zespół zdobywa najwięcej punktów na sezon	7
3.4. Czy auta dziś częściej dojeżdżają do mety (niezawodność)	8
3.5. Czy auta z roku na rok jeżdżą szybciej	9
3.6. Kto wygrywa z kolegą z tego samego zespołu	10
3.7. Wykres zbiorczy	11
4. Podsumowanie i wnioski	11
Ograniczenia i co dalej	12
5. Załączniki	12
Użyte narzędzia	12
Jak uruchomić	12

1. Co badamy i dlaczego

W Formule 1 wynik na torze zależy nie tylko od kierowcy, ale przede wszystkim od techniki — od tego, jak dobry jest bolid. Co kilka lat zmieniają się przepisy (np. inny rodzaj silnika), a inżynierowie budują coraz lepsze auta. Każda taka zmiana zostawia ślad w liczbach: w czasach okrążeń, w liczbie zwycięstw, w tym ile aut dojeżdża do mety.

Cel projektu: sprawdzić na liczbach, jak postęp techniczny zmieniał wyścigi przez 77 sezonów (lata 1950–2026). Patrzymy na trzy rzeczy: jak szybkie były auta, jak bardzo były awaryjne i jak wyrównana była walka między zespołami.

Pytania, na które szukamy odpowiedzi:

- **Czy auta dziś rzadziej się psują niż kiedyś?** Czyli: czy dojechanie do mety stało się normą?
- **Czy auta z roku na rok jeżdżą coraz szybciej?** Czy może czasem zwalniają, bo nowe przepisy „cofają” rozwój?
- **Czy widać, że pełny bak paliwa spowalnia auto?** I czy widać w danych zakaz tankowania w czasie wyścigu (wprowadzony w 2010 roku)?
- **Czy zawsze wygrywają te same 2–3 zespoły, czy walka bywa bardziej wyrównana?**
- **Czy liczby pokazujące „talent” kierowcy są uczciwe?** Czy łatwo nimi zmanipulować wynik?

Projekt jest **opisowy** — to znaczy, że opisujemy i tłumaczymy, co się działo, ale nie przewidujemy przyszłości. Ważne: przy każdej liczbie mówimy też, kiedy może ona mylić. Pokazanie słabości danej miary jest tak samo

cenne jak sama liczba.

2. Skąd dane i co zawierają

2.1. Skąd wzięliśmy dane

Dane pochodzą z darmowej, publicznej bazy wyników F1 (projekt **Ergast**, udostępniony na platformie **Kaggle**). To zwykłe pliki **CSV** (tabele z danymi, jak w Excelu).

Pliki wczytujemy do **DuckDB**. DuckDB to mała baza danych, która rozumie język **SQL** (język do zadawania pytań danym, np. „pokaż wszystkie wyścigi z 2020 roku”). Działa szybko i nie wymaga osobnego serwera — uruchamia się od razu w programie. Dzięki temu możemy zadawać pytania nawet do bardzo dużych tabel (setki tysięcy wierszy) i od razu dostawać wynik w Pythonie.

```
# Pobierz pliki CSV z Kaggle i wczytaj każdy jako osobną tabelę w bazie
race_data = kagglehub.dataset_download("jtrotman/formula-1-race-data")
conn = duckdb.connect("f1.db")
for f in glob.glob(f"{race_data}/*.csv"):
    name = os.path.splitext(os.path.basename(f))[0]
    conn.execute(f"CREATE OR REPLACE TABLE {name} AS SELECT * FROM read_csv_auto('{f}')
```

2.2. Jak duże są dane

Co	Ile
Zakres lat	1950 – 2026
Liczba sezonów	77
Liczba wyścigów (Grand Prix)	1 171
Liczba kierowców	865
Liczba zespołów (konstruktorów)	214
Liczba torów	78
Liczba pojedynczych okrążeń (tabela lap_times)	871 076

Ważne o latach: nie każda analiza obejmuje pełne 1950–2026. Niektóre dane zaczęto zapisywać później — np. czasy pojedynczych okrążeń istnieją dopiero od lat 80./90. Sezon 2026 jest **w trakcie** (jeszcze się nie skończył), więc ostatni punkt na wykresach trzeba czytać ostrożnie.

2.3. Najważniejsze tabele

Tabela = arkusz z danymi. Każda ma swój temat. Łączymy je ze sobą po wspólnych numerach (tzw. identyfikatorach, np. `raceId` = numer wyścigu).

Tabela	Liczba wierszy	Co zawiera
<code>races</code>	1 171	Kalendarz wyścigów: rok, runda, tor, data
<code>results</code>	27 348	Wyniki: zajęte miejsce, punkty, czy auto dojechało do mety
<code>lap_times</code>	871 076	Czas każdego pojedynczego okrążenia
<code>qualifying</code>	11 080	Wyniki kwalifikacji (walka o miejsce startowe)
<code>pit_stops</code>	22 249	Postoje w boksie (zmiana opon itd.)

Tabela	Liczba wierszy	Co zawiera
<code>drivers</code>	865	Kierowcy: imię, nazwisko, narodowość, data urodzenia
<code>constructors</code>	214	Zespoły: nazwa, narodowość
<code>status</code>	140	Słownik powodów zakończenia (np. „dojechał”, „silnik”, „kolizja”)
<code>circuits</code>	78	Tory: nazwa, kraj, położenie

2.4. Czyszczenie danych przed analizą

Surowe dane nigdy nie są idealne. Zanim coś policzymy, trzeba je posprzątać:

- **Braki danych** — gdy czegoś brakuje, w plikach jest znak `\N`. Takie wiersze pomijamy lub oznaczamy jako „puste”.
- **Łączenie tabel** — sklejamy tabele po wspólnych numerach (np. wynik + nazwa kierowcy + nazwa toru).
- **Czas w milisekundach** — czasy okrążeń zamieniamy na milisekundy, żeby dało się je dodawać i porównywać.
- **Usuwanie dziwnych wartości (metoda IQR)** — IQR to prosty sposób na wyrzucenie wartości skrajnych. Np. okrążenie podczas postoju w boksie jest bardzo wolne i zaburzyłoby wynik, więc je odrzucamy.
- **Czy auto dojechało do mety** — z powodu zakończenia robimy prostą informację: „dojechał” albo „nie dojechał”.

3. Analiza danych


Zrobiliśmy sześć osobnych analiz. Każda działa tak samo: pytamy bazę o dane (SQL), liczymy w Pythonie (`pandas`, `numpy`) i rysujemy wykres (`matplotlib`, `seaborn`). Gdzie trzeba, rysujemy też **linię trendu** — gładką krzywą, która pokazuje ogólny kierunek mimo wahań.

3.1. Jak ciężar paliwa wpływa na czas okrążenia


Co robimy. Bierzemy dwa tory, które najczęściej gościły wyścigi (Silverstone i Hungaroring). Patrzymy, jak zmienia się czas okrążenia w trakcie jednego wyścigu. Dzielimy historię na dwa okresy: **gdy wolno było tankować w czasie wyścigu (1994–2009)** i **gdy zakazano tankowania (od 2010)**.

Wynik. Im więcej paliwa się spali, tym auto jest lżejsze i szybsze — czasy okrążeń maleją w trakcie wyścigu. Efekt jest **mocniejszy po 2010 roku**, bo wtedy auta startują z paliwem na cały wyścig (są cięższe na starcie). Ten sam wzór widać na **obu torach** — czyli to naprawdę wina ciężaru paliwa, a nie przypadek na jednym torze.


Silverstone Circuit: Wpływ Masy Paliwa na Lap Time & Postęp Techniczny (1994-2026)
Trendy pokazują ogólny kierunek zmian technicznych
Lap Time Progression (Within Race)






Lap 1 Trend Through Years (Full Fuel Tank on Start)



Last Lap Trend Through Years (Fuel Burned = Lighter Car = Faster)




Hungaroring: Wpływ Paliwa na Lap Times & Postęp Techniczny (1994-2026) Trendy pokazują ogólny kierunek zmian technicznych Lap Time Progression (Within Race)



3.2. Czy 3 najlepsze zespoły zgarniają wszystko

Co robimy. Dla każdego sezonu liczymy, jaki **procent** wszystkich punktów zdobyły 3 najlepsze zespoły. Liczymy procent (a nie samą liczbę punktów), bo zasady punktowania zmieniały się przez lata — procent jest sprawiedliwszy do porównań.

Wynik. Co sezon 3 czołowe zespoły biorą około 70–80% punktów. Najbardziej dominowały w latach 50. (aż ~98% w 1952). Potem walka się wyrównała (~51% na początku lat 80.), a teraz znów dominacja rośnie (np. Mercedes 2014–2020, później Red Bull). **Wniosek: dominacja kręci się w cyklach — raz większa, raz mniejsza.**




Rysunek 1: Dominacja Top-3

3.3. Który zespół zdobywa najwięcej punktów na sezon

Co robimy. Liczymy: suma wszystkich punktów zespołu ÷ liczba sezonów, w których jeździł (minimum 3 sezony).

Wynik — uwaga, tu można się pomylić. Najlepiej wypadają Mercedes (~440) i Red Bull (~370). Ale ta miara **faworyzuje nowsze zespoły**, bo dziś za jeden wyścig rozdaje się dużo więcej punktów niż kiedyś (dawniej zwycięstwo = ~8 pkt, dziś = 25 pkt + punkty dla wielu kierowców). Dlatego stare, zasłużone zespoły jak Ferrari (~150) wypadają gorzej, choć mają więcej tytułów. **Ta liczba mówi o tempie zbierania punktów dziś — a nie o tym, kto jest najlepszy w historii.**




Rysunek 2: Konstruktorzy — punkty na sezon

3.4. Czy auta dziś częściej dojeżdżają do mety (niezawodność)

Co robimy. DNF to skrót od „nie ukończył wyścigu” (ang. *Did Not Finish*). Dla każdego sezonu liczymy: ile aut nie dojechało ÷ ile wystartowało. To pokazuje, jak często auta się psuły.

Wynik. Kiedyś było bardzo źle — pod koniec lat 60. nawet ~47% aut nie kończyło wyścigu (prawie co drugie!). Dziś to tylko 10–15%. Dojechanie do mety zmieniło się z loterii w normę. **To najmocniejszy dowód, że technika poszła do przodu.** Dwa zastrzeżenia: (1) do DNF liczą się też wypadki i kolizje, nie tylko awarie; (2) mały wzrost na końcu wykresu to niedokończony sezon 2026, a nie realne pogorszenie.




Rysunek 3: Trend DNF

3.5. Czy auta z roku na rok jeżdżą szybciej

Co robimy. Z każdego wyścigu bierzemy jedno **najszybsze okrążenie**, a potem liczymy średnią dla każdego roku. Sprawdzamy, czy czasy z roku na rok spadają (szybciej = lepiej).

Wynik.auta **nie** robiły się szybsze równo z roku na rok. Najszybciej było na początku lat 2000. Potem przyszły nowe przepisy w 2009 (mniej aerodynamiki) i 2014 (cięższe silniki hybrydowe) i auta **zwolniły**, a dopiero później znów nadrabiały. Czyli postęp nie jest stały — **co kilka lat przepisy „resetują” rozwój**. Uwaga: różne tory mają różną długość, więc patrzymy na ogólny trend, a nie na pojedyncze lata.




Rysunek 4: Najszybsze okrążenia

3.6. Kto wygrywa z kolegą z tego samego zespołu

Co robimy. Dwóch kierowców z tego samego zespołu jeździ takim samym autem — więc kto wyżej, ten lepszy danego dnia. Liczymy, jaki procent takich „pojedynków” wygrał każdy kierowca (bierzemy kierowców z min. 50 wspólnymi wyścigami).


Wynik. Najwyżej jest Verstappen (~83%), nisko Hamilton (~58%). Ale ranking trzeba czytać ostrożnie: łatwiej wygrywać, gdy ma się słabszego partnera, a trudniej, gdy partner jest mocny. Dodatkowo liczymy tylko wyścigi, które obaj ukończyli (awarie pomijamy), i nie bierzemy pod uwagę, jak silny był rywal. **Ta liczba mówi „jak często bił swojego kolegę” — a nie kto jest najlepszy w ogóle.**



Rysunek 5: Pojedynki w zespole

3.7. Wykres zbiorczy

Najważniejsze wyniki (niezawodność, szybkość, dominacja, wpływ paliwa) zebraliśmy na jednym wspólnym obrazku.



Rysunek 6: Panel zbiorczy

4. Podsumowanie i wnioski

Czego nauczyły nas dane:

1. **Auta są dużo bardziej niezawodne niż kiedyś.** Odsetek aut, które nie kończą wyścigu, spadł 3–4 razy od lat 60. To najwyraźniejszy dowód postępu technicznego.
2. **Pełny bak realnie spowalnia auto.** Widać to na różnych torach i w różnych latach — a zakaz tankowania z 2010 roku jest dobrze widoczny w danych.
3. **Dominacja zespołów chodzi w cyklach.** Czasem walka jest wyrównana, czasem rządzi jeden zespół. Teraz dominacja znów rośnie.
4. **Auta nie jeżdżą szybciej co roku.** Nowe przepisy dwa razy (2009 i 2014) cofnęły rozwój. Postęp nie jest równy.
5. **Niektóre „rankingi talentu” potrafią mylić.** Trzeba uważać, jak liczy się dane wskaźniki — bo łatwo wyciągnąć z nich błędny wniosek.

Ograniczenia i co dalej

- Miara „punkty na sezon” faworyzuje nowsze zespoły — można ją poprawić, licząc punkty sprawiedliwiej w obrębie każdego sezonu albo patrząc na liczbę tytułów.
- Analiza najszybszych okrążeń miesza tory o różnej długości — można to poprawić, uwzględniając długość toru.
- Projekt tylko **opisuje** przeszłość. Następny krok to **przewidywanie sezonu 2026** — czyli model uczenia maszynowego (np. Random Forest), który na podstawie lat ze zmianą przepisów (2014, 2022) spróbuje zgadnąć, jak zmieni się układ sił. Dane są już przygotowane, ale model jeszcze nie powstał.

5. Załączniki

Załącznik	Gdzie	Co to
Kod źródłowy (notebook)	Project1.ipynb	Cały kod: wczytanie danych → pytania SQL → analiza → wykresy
Baza danych	f1.db	Lokalna baza DuckDB z danymi F1 (1950–2026)
Lista zależności	pyproject.toml	Spis bibliotek potrzebnych do uruchomienia
Prezentacja (slajdy)	pres/F1Pandas/slides.md	Prezentacja w formacie Slidev (Markdown)
Prezentacja (PDF)	pres/F1Pandas/slides-export.pdf	Prezentacja jako PDF
Prezentacja (PPTX)	pres/F1Pandas/slides-export.pptx	Prezentacja jako PowerPoint
Wykresy	pres/F1Pandas/images/	Gotowe obrazki (PNG)

Użyte narzędzia

- **Język:** Python (wersja 3.13 lub nowsza)
- **Baza danych:** DuckDB (pytania w języku SQL)
- **Liczenie na danych:** pandas, numpy
- **Wykresy:** matplotlib, seaborn
- **Pobieranie danych:** kagglehub (zbiór F1 z Kaggle)
- **Prezentacja:** Slidev

Jak uruchomić

```
uv sync          # zainstaluj potrzebne biblioteki
uv run jupyter notebook  # otwórz notebook Project1.ipynb
```